

# Lab4-Bayesian-Methods-student

November 16, 2025

## 1 Laboratorium 4: Metody Bayesowskie

Cel: praktyczne zastosowanie metod bayesowskich do klasyfikacji i regresji oraz implementacja online'owej regresji liniowej Bayesa.

Wskazówki dot. środowiska - Używamy numpy, pandas, scikit-learn, matplotlib

```
[1]: import os, sys, math, json, warnings
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split, KFold, cross_val_score,
    ↪StratifiedKFold
from sklearn.metrics import (
    accuracy_score, f1_score, precision_score, recall_score, confusion_matrix,
    ↪ConfusionMatrixDisplay,
    roc_auc_score, classification_report, brier_score_loss, mean_squared_error,
    ↪r2_score
)
from sklearn.preprocessing import StandardScaler, PowerTransformer,
    ↪OneHotEncoder, PolynomialFeatures
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.naive_bayes import GaussianNB, MultinomialNB, ComplementNB,
    ↪BernoulliNB
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import BayesianRidge, Ridge, LinearRegression
from sklearn.calibration import CalibratedClassifierCV, calibration_curve
from sklearn import datasets

warnings.filterwarnings("ignore")
np.random.seed(42)
```

### 1.1 Zadanie 1: Gaussowski Naiwny Klasyfikator Bayesa

- Zaimplementuj Gaussian Naive Bayes. Predykcję klasy wykonuj poprzez maksymalizację posterioru

- Przetestuj klasyfikator dla danych: Breast Cancer Wisconsin (30 cech, `sklearn.datasets.load_breast_cancer`)
  - Zawiera 569 próbek komórek pobranych z biopsji sutka. Każda próbka została oznaczona jako: M (malignant) - złośliwy nowotwór, B (benign) - łagodny nowotwór.
  - Każda próbka jest opisana 30 cechami numerycznymi, wyliczonymi z obrazu mikroskopowego jądra komórkowego.
- Utwórz pipeline: `PowerTransformer(yeo-johnson)` → opcjonalnie PCA → Twój `GaussianNBFromScratch`
  - `PowerTransformer` umożliwia stabilizację wariancji i przybliżenie rozkładu danych do normalnego (Gaussa)
  - Metoda Yeo-Johnson jest podobna do transformacji Box-Coxa, ale obsługuje również wartości ujemne i zero, co czyni ją bardziej uniwersalną.
- Wyznacz metryki: `accuracy`, `precision`, `recall`, `f1`, macierz pomyłek, **krzywe kalibracji** oraz **Brier score**
  - **Krzywa kalibracji** to wykres, który pokazuje zgodność między przewidywanym prawdopodobieństwem a rzeczywistą częstością zdarzenia
  - Idealny model: punkty leżą na przekątnej ( $y = x$ ) → oznacza idealną kalibrację
  - Jeśli punkty są poniżej przekątnej → model zbyt pewny siebie (przecenia swoje prognozy)
  - Jeśli powyżej → model zbyt ostrożny (niedoszacowuje prawdopodobieństw)
  - **Brier score** to miara błędu prognozy probabilistycznej, która ocenia, jak bliskie są przewidywane prawdopodobieństwa wartościom rzeczywistym (0 lub 1).
  - Zakres: 0 → idealna kalibracja, 1 → najgorsza możliwa.
- Porównaj z `sklearn.naive_bayes.GaussianNB` i skomentuj różnice

```
[2]: class GaussianNBFromScratch:
    def __init__(self, var_smoothing=1e-9):
        self.var_smoothing = var_smoothing
        self.classes_ = None
        self.class_prior_ = None
        self.theta_ = None # średnie [n_classes, n_features]
        self.sigma_ = None # wariancje [n_classes, n_features]

    def fit(self, X, y):
        X = np.asarray(X, dtype=float)
        y = np.asarray(y)
        self.classes_, y_idx = np.unique(y, return_inverse=True)
        n_classes = len(self.classes_)
        n_features = X.shape[1]

        self.theta_ = np.zeros((n_classes, n_features))
        self.sigma_ = np.zeros((n_classes, n_features))
        self.class_prior_ = np.zeros(n_classes)

        for k in range(n_classes):
            mask = y_idx == k
            X_k = X[mask]
            self.theta_[k] = np.mean(X_k, axis=0)
```

```

        self.sigma_[k] = np.var(X_k, axis=0) + self.var_smoothing
        self.class_prior_[k] = np.sum(mask) / len(y)

    return self

def _log_gaussian_density(self, X):
    X = np.asarray(X, dtype=float)
    n_samples = X.shape[0]
    n_classes = len(self.classes_)
    log_probs = np.zeros((n_samples, n_classes))

    for k in range(n_classes):
        diff = X - self.theta_[k]
        log_var = np.log(2 * np.pi * self.sigma_[k])
        squared_diff = diff ** 2 / self.sigma_[k]
        log_probs[:, k] = -0.5 * np.sum(log_var + squared_diff, axis=1)

    return log_probs

def predict_proba(self, X):
    log_likelihood = self._log_gaussian_density(X)
    log_prior = np.log(self.class_prior_)
    log_posterior = log_likelihood + log_prior

    log_posterior -= np.max(log_posterior, axis=1, keepdims=True)
    posterior = np.exp(log_posterior)
    posterior /= np.sum(posterior, axis=1, keepdims=True)

    return posterior

def predict(self, X):
    return self.classes_[np.argmax(self.predict_proba(X), axis=1)]


# ----- Załaduj dane i zbuduj pipeline -----
from sklearn.decomposition import PCA

X, y = datasets.load_breast_cancer(return_X_y=True, as_frame=True)
num_features = X.columns.tolist()

preprocess = ColumnTransformer(
    transformers=[
        ("num", PowerTransformer(method="yeo-johnson"), num_features),
    ],
    remainder="drop"
)

```

```

pipeline_student = Pipeline([
    ("prep", preprocess),
    ("pca", PCA(n_components=0.95, svd_solver="full")),
    ("gnb", GaussianNBFromScratch(var_smoothing=1e-9))
])

skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
pipeline_sklearn = Pipeline([("prep", preprocess), ("pca", PCA(n_components=0.
    ↪95, svd_solver="full")), ("gnb", GaussianNB(var_smoothing=1e-9))])

y_true_s, y_pred_s, y_proba_s = [], [], []
y_true_sk, y_pred_sk, y_proba_sk = [], [], []

for train_idx, val_idx in skf.split(X, y):
    X_train, X_val = X.iloc[train_idx], X.iloc[val_idx]
    y_train, y_val = y.iloc[train_idx], y.iloc[val_idx]

    pipeline_student.fit(X_train, y_train)
    pipeline_sklearn.fit(X_train, y_train)

    y_pred_s.extend(pipeline_student.predict(X_val))
    y_proba_s.extend(pipeline_student.predict_proba(X_val)[:, 1])
    y_pred_sk.extend(pipeline_sklearn.predict(X_val))
    y_proba_sk.extend(pipeline_sklearn.predict_proba(X_val)[:, 1])
    y_true_s.extend(y_val)
    y_true_sk.extend(y_val)

y_true_s, y_pred_s, y_proba_s = np.array(y_true_s), np.array(y_pred_s), np.
    ↪array(y_proba_s)
y_true_sk, y_pred_sk, y_proba_sk = np.array(y_true_sk), np.array(y_pred_sk), np.
    ↪array(y_proba_sk)

print("Student:", f"acc={accuracy_score(y_true_s, y_pred_s):.6f},"
    ↪f1={f1_score(y_true_s, y_pred_s):.6f}, brier={brier_score_loss(y_true_s, y_proba_s):.6f}")
print("Sklearn:", f"acc={accuracy_score(y_true_sk, y_pred_sk):.6f},"
    ↪f1={f1_score(y_true_sk, y_pred_sk):.6f}, brier={brier_score_loss(y_true_sk, y_proba_sk):.6f}")
print(f"Różnica w prawdopodobieństwach: max={np.max(np.abs(y_proba_s - y_proba_sk)):.10f}")

fig, axes = plt.subplots(1, 2, figsize=(12, 5))
for ax, y_true, y_proba, title in zip(axes, [y_true_s, y_true_sk], [y_proba_s, y_proba_sk], ['Student', 'Sklearn']):
    frac_pos, mean_pred = calibration_curve(y_true, y_proba, n_bins=10)
    ax.plot(mean_pred, frac_pos, 'o-')

```

```

ax.plot([0, 1], [0, 1], 'k--')
ax.set_xlabel('Mean Predicted Probability')
ax.set_ylabel('Fraction of Positives')
ax.set_title(title)
ax.grid(True)
plt.tight_layout()
plt.show()

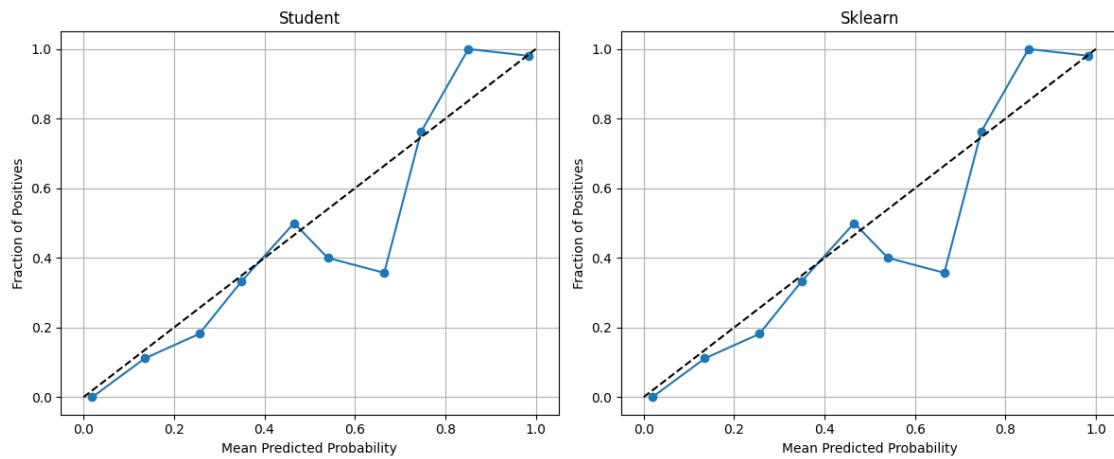
ConfusionMatrixDisplay.from_predictions(y_true_s, y_pred_s)
plt.title('Student')
plt.show()

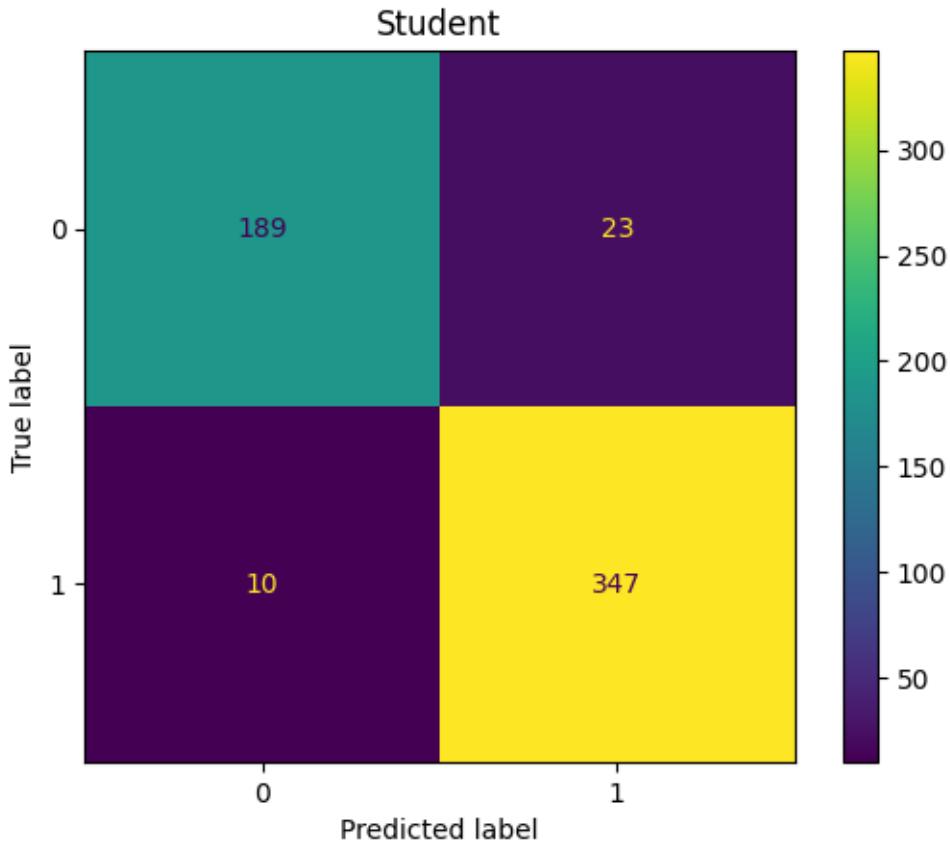
```

Student: acc=0.942004, f1=0.954608, brier=0.040748

Sklearn: acc=0.942004, f1=0.954608, brier=0.040748

Różnica w prawdopodobieństwach: max=0.0000000691





## 1.2 Zadanie 2: Multinomial/Complement Naive Bayes

- Zbiór danych **20 Newsgroups**
  - Zawiera około 18000 wiadomości tekstowych z 20 różnych grup dyskusyjnych (newsgroups) z lat 90
  - Każdy dokument reprezentuje post z forum internetowego, przypisany do jednej z 20 kategorii tematycznych
- Użyj `TfidfVectorizer` + `MultinomialNB` (rozkład wielomianowy) do klasyfikacji wiadomości tekstowych (20NG)
  - `ngram_range=(1, 2)`: unigramy oraz bigramy
  - `min_df=2`
  - `max_df=0.9`
  - `stop_words="english"`
  - `alpha`: additive (Laplace/Lidstone) smoothing parameter (set `alpha=0` and `force_alpha=True`, for no smoothing).
- Porównaj z `ComplementNB` (często lepszy przy niezbalansowanych danych)
  - `ComplementNB` zamiast obliczać prawdopodobieństwa dla klasy bezpośrednio, używa danych komplementarnych, tzn. bierze pod uwagę wszystkie pozostałe klasy oprócz danej
  - W ten sposób poprawia stabilność i dokładność klasyfikacji, szczególnie dla

niezrównoważonych danych.

- **Metryki i analiza:** accuracy, macro-F1, raport per-klasa, top-słowa dla wybranych klas, wpływ alpha (Laplace/Lidstone smoothing)

```
[3]: from sklearn.datasets import fetch_20newsgroups

train = fetch_20newsgroups(subset='train', shuffle=True, random_state=42)
test = fetch_20newsgroups(subset='test', shuffle=True, random_state=42)
X_train, y_train = train.data, train.target
X_test, y_test = test.data, test.target

pipeline_mnb = Pipeline([
    ('tfidf', TfidfVectorizer(ngram_range=(1, 2), min_df=2, max_df=0.9, stop_words='english')),
    ('mnb', MultinomialNB(alpha=1.0))
])

pipeline_cnb = Pipeline([
    ('tfidf', TfidfVectorizer(ngram_range=(1, 2), min_df=2, max_df=0.9, stop_words='english')),
    ('cnb', ComplementNB(alpha=1.0))
])

pipeline_mnb.fit(X_train, y_train)
pipeline_cnb.fit(X_train, y_train)

y_pred_mnb = pipeline_mnb.predict(X_test)
y_pred_cnb = pipeline_cnb.predict(X_test)

print("MultinomialNB:")
print(f"Accuracy: {accuracy_score(y_test, y_pred_mnb):.4f}")
print(f"Macro-F1: {f1_score(y_test, y_pred_mnb, average='macro'):.4f}")
print("\nComplementNB:")
print(f"Accuracy: {accuracy_score(y_test, y_pred_cnb):.4f}")
print(f"Macro-F1: {f1_score(y_test, y_pred_cnb, average='macro'):.4f}")

print("\n==== Classification Report (MultinomialNB) ===")
print(classification_report(y_test, y_pred_mnb, target_names=train.target_names))

print("\n==== Classification Report (ComplementNB) ===")
print(classification_report(y_test, y_pred_cnb, target_names=train.target_names))

vectorizer = pipeline_mnb.named_steps['tfidf']
mnb_model = pipeline_mnb.named_steps['mnb']
feature_names = vectorizer.get_feature_names_out()
```

```

for class_idx in [0, 1, 2]:
    class_name = train.target_names[class_idx]
    log_probs = mnb_model.feature_log_prob_[class_idx]
    top_indices = np.argsort(log_probs)[-10:][::-1]
    top_words = [feature_names[i] for i in top_indices]
    print(f"\nTop 10 słów dla klasy '{class_name}':")
    print(top_words)

alphas = [0.1, 0.5, 1.0, 2.0, 5.0]
print("\n==== Wpływ alpha na MultinomialNB ====")
for alpha in alphas:
    model = Pipeline([
        ('tfidf', TfidfVectorizer(ngram_range=(1, 2), min_df=2, max_df=0.9, stop_words='english')),
        ('mnb', MultinomialNB(alpha=alpha))
    ])
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
    print(f"alpha={alpha}: acc={accuracy_score(y_test, y_pred):.4f}, f1={f1_score(y_test, y_pred, average='macro'):.4f}")

```

MultinomialNB:

Accuracy: 0.8093  
Macro-F1: 0.7966

ComplementNB:

Accuracy: 0.8320  
Macro-F1: 0.8236

==== Classification Report (MultinomialNB) ===

	precision	recall	f1-score	support
alt.atheism	0.80	0.74	0.77	319
comp.graphics	0.75	0.73	0.74	389
comp.os.ms-windows.misc	0.80	0.69	0.74	394
comp.sys.ibm.pc.hardware	0.64	0.76	0.70	392
comp.sys.mac.hardware	0.85	0.77	0.81	385
comp.windows.x	0.84	0.78	0.81	395
misc.forsale	0.79	0.82	0.81	390
rec.autos	0.87	0.88	0.87	396
rec.motorcycles	0.91	0.93	0.92	398
rec.sport.baseball	0.86	0.91	0.88	397
rec.sport.hockey	0.83	0.97	0.90	399
sci.crypt	0.80	0.94	0.87	396
sci.electronics	0.84	0.66	0.74	393
sci.med	0.88	0.75	0.81	396
sci.space	0.80	0.93	0.86	394

soc.religion.christian	0.70	0.94	0.80	398
talk.politics.guns	0.70	0.92	0.80	364
talk.politics.mideast	0.93	0.93	0.93	376
talk.politics.misc	0.92	0.57	0.70	310
talk.religion.misc	0.91	0.33	0.48	251
accuracy			0.81	7532
macro avg	0.82	0.80	0.80	7532
weighted avg	0.82	0.81	0.80	7532

==== Classification Report (ComplementNB) ====

	precision	recall	f1-score	support
alt.atheism	0.79	0.79	0.79	319
comp.graphics	0.79	0.72	0.76	389
comp.os.ms-windows.misc	0.78	0.73	0.76	394
comp.sys.ibm.pc.hardware	0.69	0.74	0.72	392
comp.sys.mac.hardware	0.85	0.79	0.82	385
comp.windows.x	0.84	0.81	0.82	395
misc.forsale	0.82	0.82	0.82	390
rec.autos	0.90	0.87	0.88	396
rec.motorcycles	0.92	0.96	0.94	398
rec.sport.baseball	0.86	0.91	0.89	397
rec.sport.hockey	0.88	0.98	0.93	399
sci.crypt	0.85	0.96	0.90	396
sci.electronics	0.83	0.68	0.75	393
sci.med	0.88	0.83	0.86	396
sci.space	0.84	0.93	0.88	394
soc.religion.christian	0.78	0.95	0.86	398
talk.politics.guns	0.73	0.91	0.81	364
talk.politics.mideast	0.93	0.95	0.94	376
talk.politics.misc	0.83	0.61	0.70	310
talk.religion.misc	0.85	0.52	0.65	251
accuracy			0.83	7532
macro avg	0.83	0.82	0.82	7532
weighted avg	0.83	0.83	0.83	7532

Top 10 słów dla klasy 'alt.atheism':

['keith', 'edu', 'god', 'caltech edu', 'caltech', 'atheists', 'atheism', 'livesey', 'edu keith', 'com']

Top 10 słów dla klasy 'comp.graphics':

['graphics', 'edu', 'image', '3d', 'files', 'university', 'com', 'polygon', 'thanks', 'file']

```

Top 10 słów dla klasy 'comp.os.ms-windows.misc':
['windows', 'edu', 'file', 'dos', 'files', 'driver', 'drivers', 'ms', 'com',
'ax']

==== Wpływ alpha na MultinomialNB ===
alpha=0.1: acc=0.8206, f1=0.8135
alpha=0.5: acc=0.8163, f1=0.8062
alpha=1.0: acc=0.8093, f1=0.7966
alpha=2.0: acc=0.8034, f1=0.7876
alpha=5.0: acc=0.7866, f1=0.7659

```

### 1.3 Zadanie 3: Bayesian Ridge Regression (szacunek niepewności)

Użyj BayesianRidge na problemie regresyjnym (`sklearn.datasets.load_diabetes`, a w dalszej kolejności wybrany przez siebie zbiór danych np. Kaggle Bike Sharing Demand)

1. Zbuduj pipeline z odpowiednim przetwarzaniem (one-hot dla kategorii, skalowanie dla liczb)
2. Porównaj LinearRegression, Ridge, BayesianRidge pod względem RMSE i  $R^2$ .
  - LinearRegression: zwykła regresja najmniejszych kwadratów (bez regularyzacji)
  - Ridge: OLS + regularizacja L2 na wagach
  - BayesianRidge: Wersja bayesowska: priory na wagach i szum; automatyczna regularizacja.
3. Dla BayesianRidge narysuj 95% przedziały predykcyjne (`predict(return_std=True)`)
4. Oblicz przybliżony **Negative Log Predictive Density (NLPD)** zakładając normalność błędu.
  - Miara jakości modelu probabilistycznego: ocenia jak dobrze model przewiduje rozkład prawdopodobieństwa wyników, a nie tylko średnią prognozę
  - Ocenia cały rozkład predykcyjny (średnią i wariancję), nie tylko trafność predykcji
  - Jeśli model dobrze dopasowuje zarówno wartość oczekiwana, jak i niepewność, NLPD będzie niskie
  - Wysoki NLPD oznacza, że model: ma zbyt wąski rozkład (zbyt pewny siebie), albo przewiduje zbyt szerokie niepewności (za mało pewny), lub nie trafia w środek rozkładu wyników
  - Skomentuj uzyskane wyniki

```
[4]: X, y = datasets.load_diabetes(return_X_y=True, as_frame=True)

num_cols = X.columns.tolist()
pre = ColumnTransformer([("num", StandardScaler(), num_cols)], remainder="drop")

models = {
    "LR": Pipeline([("pre", pre), ("m", LinearRegression())]),
    "Ridge": Pipeline([("pre", pre), ("m", Ridge(alpha=1.0))]),
    "BayesRidge": Pipeline([("pre", pre), ("m", ↴
        BayesianRidge(compute_score=True))]),
}

X_train, X_val, y_train, y_val = train_test_split(X, y, test_size=0.3, ↴
    random_state=42)
```

```

results = []
for name, model in models.items():
    model.fit(X_train, y_train)
    y_pred = model.predict(X_val)
    rmse = np.sqrt(mean_squared_error(y_val, y_pred))
    r2 = r2_score(y_val, y_pred)
    results[name] = {'RMSE': rmse, 'R^2': r2}
    print(f"{name}: RMSE={rmse:.4f}, R^2={r2:.4f}")

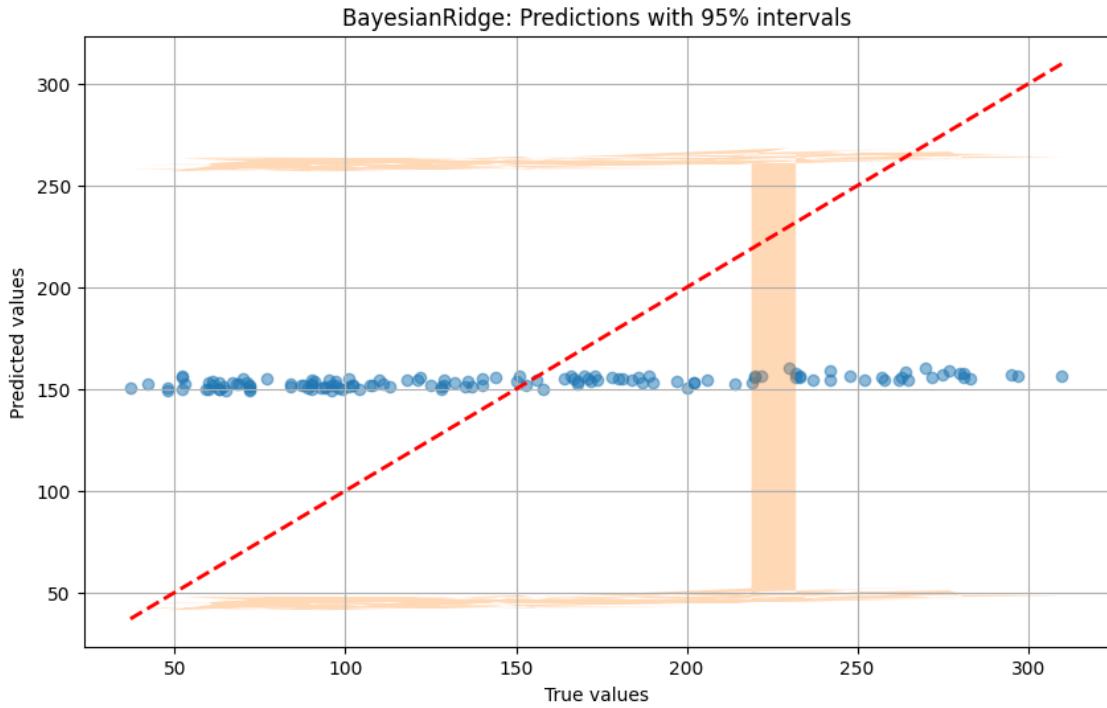
bayes_model = models['BayesRidge']
y_pred_bayes, y_std_bayes = bayes_model.named_steps['m'].predict(X_val, ↴
    return_std=True)

plt.figure(figsize=(10, 6))
plt.scatter(y_val, y_pred_bayes, alpha=0.5)
plt.plot([y_val.min(), y_val.max()], [y_val.min(), y_val.max()], 'r--', lw=2)
plt.fill_between(y_val, y_pred_bayes - 1.96*y_std_bayes, y_pred_bayes + 1.96*y_std_bayes, alpha=0.3)
plt.xlabel('True values')
plt.ylabel('Predicted values')
plt.title('BayesianRidge: Predictions with 95% intervals')
plt.grid(True)
plt.show()

nlpd = -np.mean(-0.5 * np.log(2 * np.pi * y_std_bayes**2) - 0.5 * ((y_val - y_pred_bayes) / y_std_bayes)**2)
print(f"\nNLPD (Negative Log Predictive Density): {nlpd:.4f}")

```

LR: RMSE=53.1202, R<sup>2</sup>=0.4773  
 Ridge: RMSE=53.1035, R<sup>2</sup>=0.4776  
 BayesRidge: RMSE=53.0561, R<sup>2</sup>=0.4785



NLPD (Negative Log Predictive Density): 5.7818

#### 1.4 Zadanie 4: Regresja liniowa Bayesa *online* (implementacja)

- Zaimplementuj Liniową Regresję Bayesowską w wersji online korzystając z klasy pomocniczej. Zastosuj wzory ze slajdów wykładu.
  - Posterior:

$$\begin{aligned}
 p(w_{i+1}|w_i, x_i, t_i) &= N(w_{i+1}|m_{i+1}, S_{i+1}) \\
 S_{i+1} &= (S_i^{-1} + \beta x_i x_i^T)^{-1} \\
 m_{i+1} &= S_{i+1}(S_i^{-1}m_i + \beta t_i x_i)
 \end{aligned}$$

- Predykcja:

$$\begin{aligned}
 \mu_i &= w_i^T x_i \\
 \sigma_i^2 &= \beta^{-1} + x_i^T S_i x_i
 \end{aligned}$$

- Następnie wygeneruj dane  $t = -0.2 + 0.6x + \varepsilon$ ,  $\varepsilon \sim N(0, 0.2^2)$  i zwizualizuj kolejne aktualizacje (kontury prior/posterior w przestrzeni  $w_1, w_2$  oraz rozrzut punktów i przedziały predykcyjne)
- Podpowiedzi:** zob. wzory (76)–(81) i sekwencję aktualizacji na slajdach „Online belief updating”

```
[5]: class BayesianLinearRegressionOnline:
    def __init__(self, n_features, alpha=2.0, beta=25.0):
```

```

        self.n_features = n_features
        self.alpha = alpha
        self.beta = beta
        self.m = np.zeros(n_features) # mean
        self.S = np.eye(n_features) / alpha # covariance ( $S_0 = \frac{1}{\alpha} I$ )

    def update(self, x, t):
        x = np.asarray(x).reshape(-1,1)
        S_inv = np.linalg.inv(self.S)
        S_new = np.linalg.inv(S_inv + self.beta * (x @ x.T))
        m_new = S_new @ (S_inv @ self.m + self.beta * t * x.flatten())
        self.S = S_new
        self.m = m_new.reshape(-1)

    def predict(self, x):
        x = np.asarray(x).reshape(-1,1)
        mean = float(self.m @ x.flatten())
        var = float(1.0/self.beta + (x.T @ self.S @ x).item())
        return mean, var

# ----- Dane syntetyczne -----
n = 20
xs = np.linspace(-1, 1, n)
true_w = np.array([-0.2, 0.6]) # [w1, w2]
noise_std = 0.2
ts = true_w[0] + true_w[1]*xs + np.random.normal(0, noise_std, size=n)

model = BayesianLinearRegressionOnline(n_features=2, alpha=2.0, beta=25.0)

from scipy.stats import multivariate_normal

X_data = np.column_stack([np.ones(len(xs)), xs])

fig, axes = plt.subplots(2, 4, figsize=(16, 8))
axes = axes.flatten()

for i in range(7):
    ax = axes[i]
    x_i = X_data[i]
    t_i = ts[i]

    w1_range = np.linspace(-0.5, 0.1, 50)
    w2_range = np.linspace(0.3, 0.9, 50)
    W1, W2 = np.meshgrid(w1_range, w2_range)

    pos = np.dstack((W1, W2))
    rv = multivariate_normal(model.m, model.S)

```

```

Z = rv.pdf(pos)

ax.contour(W1, W2, Z, levels=10)
ax.scatter(true_w[0], true_w[1], c='r', marker='x', s=100, label='True w')
ax.scatter(model.m[0], model.m[1], c='b', marker='o', s=50, □
    ↪label='Posterior mean')
ax.set_xlabel('w1')
ax.set_ylabel('w2')
ax.set_title(f'After {i+1} updates')
ax.legend()
ax.grid(True)

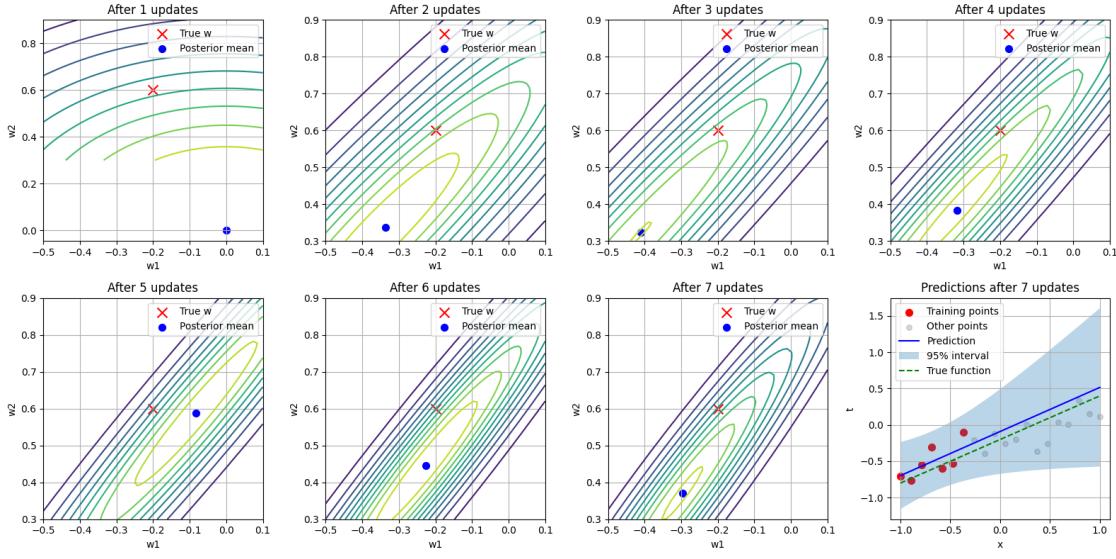
model.update(x_i, t_i)

ax = axes[7]
x_plot = np.linspace(-1, 1, 100)
X_plot = np.column_stack([np.ones(len(x_plot)), x_plot])
y_pred = np.array([model.predict(x)[0] for x in X_plot])
y_std = np.array([np.sqrt(model.predict(x)[1]) for x in X_plot])

ax.scatter(xs[:7], ts[:7], c='r', label='Training points', s=50)
ax.scatter(xs[7:], ts[7:], c='gray', alpha=0.3, label='Other points', s=30)
ax.plot(x_plot, y_pred, 'b-', label='Prediction')
ax.fill_between(x_plot, y_pred - 1.96*y_std, y_pred + 1.96*y_std, alpha=0.3, □
    ↪label='95% interval')
ax.plot(x_plot, true_w[0] + true_w[1]*x_plot, 'g--', label='True function')
ax.set_xlabel('x')
ax.set_ylabel('t')
ax.set_title('Predictions after 7 updates')
ax.legend()
ax.grid(True)

plt.tight_layout()
plt.show()

```



## 1.5 Zadanie 5: Decyzja z kosztami i kalibracja (Adult Income) - dodatkowe

**Cel:** zbudować klasyfikator dochodu ( $>50K$  vs.  $50K$ ), skalibrować jego prawdopodobieństwa oraz wybrać próg decyzji  $\tau$ , który minimalizuje oczekiwany stratę dla zadanej macierzy kosztów.

**Teoria:** - Decyzja minimalizująca prawdopodobieństwo błędu: wybierz klasę o większym  $P(C_k|x)$   
- Koszty/straty: dla macierzy  $L$  szukamy progu  $\tau$ , który minimalizuje  $\mathbb{E}[L]$  - Kalibracja (np. izotoniczna) poprawia zgodność estymowanych  $P(C_k|x)$  z częstościami empirycznymi

**Wykorzystaj:** - **GaussianNB + OneHotEncoder/StandardScaler** (pipeline), **CalibratedClassifierCV** (`method="isotonic"`), - Wykres **calibration curve**, **Brier score** i przeszukiwanie  $\tau$  podadaną macierzą kosztów

**Polecenia:** 1. Wczytaj zbiór danych *Adult Income* z OpenML 3. **Przygotowanie cech (ColumnTransformer):** `OneHotEncoder(handle_unknown="ignore")` dla kategorycznych, `StandardScaler` dla liczbowych. Densyfikacja połączonej macierzy.

4. **Model bazowy:** `GaussianNB` w pipeline + **kalibracja izotoniczna** (`CalibratedClassifierCV`)

- Dzielimy dane: **70% tren, 30% walidacja** (stratyfikacja)

- Używamy `CalibratedClassifierCV` (izotoniczna) do poprawy kalibracji  $P(C_k = 1|x)$  - Obliczamy bazowe metryki przy progu  $\tau = 0.5$ : accuracy, precision, recall, F1, **Brier score**, oraz macierz pomyłek 5. **Ewaluacja** na zbiorze walidacyjnym: accuracy, F1, **Brier**, macierz pomyłek i **krzywa kalibracji**

6. **Decyzja uwarunkowana kosztem:** zdefiniuj macierz strat  $L$  i znajdź optymalny próg  $\tau^*$  minimalizujący  $\mathbb{E}[L]$

- Zdefiniuj **macierz strat**  $L$  dla problemu binarnego:

$$L = \begin{bmatrix} 0 & c_{01} \\ c_{10} & 0 \end{bmatrix},$$

gdzie  $c_{01}$  to koszt **falszywego alarmu (FP)**, a  $c_{10}$  to koszt **przeoczenia pozytywnej klasy**

(FN). - Dla danego progu  $\tau$  i predykcji szacujemy średni koszt decyzji - Wykonaj obliczenia z **kosztem FN pięciokrotnie większym** od FP:  $c_{10} = 5, c_{01} = 1$ , wyznaczając optymalne  $\tau^*$  7. Przedstaw raport końcowy dla  $\tau^*$ : metryki i macierz pomyłek

8. Powtórz eksperyment z innymi kosztami L 9. Przedstaw podsumowanie i wnioski. Co dzieje się z optymalnym progiem  $\tau^*$  gdy zmieniają się proporcje między  $c_{10}$ , a  $c_{01}$ ?